

第67回 コンピュータビジョン勉強会@関東（前編）

CV × Scientific Figures

Hosei Univ. (Iyatomi Lab.)

Takuro Kawada

※ 本発表で紹介する図や数式は対象論文から引用しています



川田拓朗

HP: lychee1223.github.io / X: [@lychee1223_Lab](https://twitter.com/lychee1223_Lab)



経歴

- '21/04 ~ 法政大学 彌富研
- '25/04 ~ 法政大学大学院 彌富研 M2
- '27/04 ~ D進予定

AI for Science × グラフィックデザイン

- 論文のポンチ絵データセットの構築 [[Kawada+, CVPRF'26](#)]

AI エージェント


- GUI エージェントの効率化 [[Takeshita+, ACL SRW'26](#)]
- 教本を用いたお手本動画不要のスポーツコーチングエージェント [[Kawada+, MIPR'26](#)]

はじめに

AI for Science

😭 科学的発見とその伝達は, 研究者の時間・労力・知識といった限られたリソースに依存

- 人工知能による科学的発見の自動化 [[Lenat, IJCAI'77](#), [Schmidhuber, AGI'10](#), [Lu+SSRN'23](#)]
人工知能による研究成果の伝達支援 [[Fu+, AAAI'22](#), [Rodriguez+, ICLR'23](#), [Tanaka+, BMVC'24](#)]



紹介する論文と選定理由

論文①

SciGA: A Comprehensive Dataset for Designing Graphical Abstracts in Academic Papers

Takuro Kawada, Shunsuke Kitada, Sota Nemoto, Hitoshi Iyatomi
Graduate School of Science and Engineering, Hosei University, Tokyo, Japan
{takuro.kawada.3g@stu., iyatomi@}hosei.ac.jp

- Findings Track
- 論文のポンチ絵推薦・生成のためのデータセットの提案

選定理由

- 主著のため

論文②

Paper2Figure: A Multi-Agent Collaborative System for Figure Generation Towards Academic Research Paper



Siwei Han^{1*} Haonian Ji^{1*} Siyang Xin^{1*} Juanquan Shi¹ Shi Qiu¹ Xinyu Ye¹
Peng Xia¹ Jiaqi Liu¹ Zhaorun Chen² Yiyang Zhou¹ Linjie Li³ Lijuan Wang³ Huaxiu Yao^{1†}
¹UNC-Chapel Hill ²University of Chicago ³Microsoft
siwei.h@cs.unc.edu, huaxiu@cs.unc.edu
*Equal contribution. †Corresponding author.

- Main Track
- 科学的忠実性と審美性の高い科学図生成エージェントの提案

選定理由

- 研究者の実フローに接地した AI for Science に興味あり
- MIRU'26 で発表する自身の研究の関連研究

現地の様子



1

SciGA | 科学図研究の基盤構築

2


Paper2Figure | 科学図を生成する

はじめに


学術論文のポンチ絵 Graphical Abstract (GA)

- 😊 読者に論文の核心を伝達し, 読むきっかけを与える Infographic [[Jeyaraman+, J. Orthop.'23](#)]
- 😊 論文の注目度・拡散力を高める [[Bennett+, Scientometrics'23](#), [Hoffberg+, Front. Res. Metr. Anal.'20](#)]
- 😭 効果的な GA の作成には高度なデザインスキルが必要 [[Jeyaraman+, Cureus'23](#)]


→ より魅力的な GA を効率よく作成するための支援技術が望まれる



[[Sharma+, CoRL'23](#)]



[[Lakhdari+, ICSOC'20](#)]




[[Morita+, CVPR'25](#)]

はじめに

1. 大規模論文データセット SciGA-145k
2. 新規推薦タスク Intra-GA Recommendation, Inter-GA Recommendation
3. 推薦タスクの新規評価指標 CAR

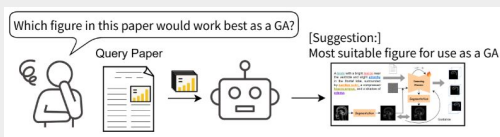
SciGA-145k Dataset

- GA 研究のデータ基盤



Intra-GA Recommendation

- 論文内から GA を選択




CAR@k

- 妥当な候補が複数存在する際の 曖昧性を考慮した推薦評価指標

$$CAR@k = \frac{p_{GT}}{p_{top-1}} \times \left(1 - \frac{1}{2} \max \left(0, \frac{H(P) - \log k/2}{H_{\max}(P) - \log k/2} \right) \right)$$


Inter-GA Recommendation

- 他の論文から参考となる GA を検索



SciGA-145k

- GA 設計支援のための論文データセット
 - 構造化されたフルテキスト
 - 関連画像 (GA, Teaser を含む)
 - メタデータ (e.g., 採択会議, 研究分野, 発行日, DOI, 著者のコメント)
- GA 理解, GA 検索, GA 生成など多様なタスクをサポート
- ライセンス: C-UDA 1.0



▼ 従来の論文データセットとの比較

Datasets	Support Contents		#Papers	#Figures	Annotations	
	Full-text	Figures			#GA	#Teaser
S2ORC [Lo+, ACL'20]	✓	✗	81,100k	N/A	N/A	N/A
unarXiv 2022 [Rodriguez+, WACV'23]	✓	✗	1,900k	N/A	N/A	N/A
Paper2fig 100k [Rodriguez+, WACV'23]	✗	✓	69k	102k	N/A	N/A
ArxivCap [Rodriguez+, WACV'23]	✗	✓	572k	6,400k	N/A	N/A
CentralFigure [Yang+, ICDAR'19]	✗	✗	7k	N/A	N/A	7,295
MMSci [Li+, arXiv'24]	✓	✓	131k	742k	N/A	N/A
SciGA-145k (ours)	✓	✓	145k	1,100k	309	30,724

SciGA-145k | 構築手順

1. [ar5iv.org](#) や [arXiv.org](#) の HTML ページからテキストと図を収集
 - ↳ TeX ソースコードを HTML に変換して公開しているプレプリントサーバ
 - HTML が不完全・破損している場合, 元のTeX ソースコードから手動収集
2. section, 数式, footnote, subfigure, subcaption を構造化
3. arXiv API でメタデータを収集
 - 研究分野は [arXiv 分類](#), [ACM CCS](#), [MSC2022](#) で収集し, 正規化
4. GA アノテーション
 - オープンアクセスな関連ジャーナルがある場合, GA を手動収集
 - 画像 GA, 動画 GA 共に収集
 - GA が論文内の図を使いまわした図か, 新規作成された図かラベル付け
 - 1ページ目にフルカラムで配置された Fig.1 を Teaser としてラベル付け


SciGA-145k | データ分析

- Abstract, GA とともに研究分野固有の特徴を持つ
- 採択会議・採択ジャーナルによるスタイル差は小さい
- 約 65 % の GA は Fig.1 の使いまわし
 - GA支援では, まず論文内の適切な図を選ぶことが重要

▼ CLIP embed. of
GAs/Teasers



▼ CLIP embed. of Abst.



- CV
- Cond. Matter
- NLP
- Math
- Network Architecture
- Others


Intra-GA Recommendation

タスク定義

- 入力: 論文
- 出力: 入力論文の図の中で GA に適した図
 - 著者に GA の提出を求めることなく, あらゆる論文で活用可能に

制約

- 概ね Fig.1 が GA として働くため, 図番号はマスクして位置バイアスを抑制



Confidence Adjusted top-1 ground truth Ratio (CAR)

Intra-GA Recommendation 評価の課題

- 論文内にはそれっぽい図が複数含まれ, モデルは許容可能なミスをする
→ instance-level で曖昧性を考慮した連続値を与える評価指標 CAR を提案



$$\text{CAR}@k = \frac{p_{\text{GT}}}{p_{\text{top-1}}} \times \left(1 - \frac{1}{2} \max \left(0, \frac{H(P) - \log k/2}{H_{\max}(P) - \log k/2} \right) \right)$$

P : normalized top- k relevance scores
 $p_{\text{top-1}}, p_{\text{GT}} \in P$: top-ranked / labeled-GA scores
 $H(P)$: entropy of P
 $H_{\max}(P) = \log k$: max entropy


GT/Top-1 比 [0, 1]

モデルの自信 [0.5, 1.0]

Confidence Adjusted top-1 ground truth Ratio (CAR)

Intra-GA Recommendation 評価の課題

- 論文内にはそれっぽい図が複数含まれ, モデルは許容可能なミスをする
→ instance-level で曖昧性を考慮した連続値を与える評価指標 CAR を提案




従来の推薦タスクの評価指標は, GT の順位に依存する

※ nDCG は各候補ごとの詳細な段階的ラベルが利用できる場合のみ連続値を与える

Confidence Adjusted top-1 ground truth Ratio (CAR)

Intra-GA Recommendation 評価の課題

- 論文内にはそれっぽい図が複数含まれ, モデルは許容可能なミスをする
→ instance-level で曖昧性を考慮した連続値を与える評価指標 CAR を提案



$$\text{CAR}@k = \frac{p_{\text{GT}}}{p_{\text{top-1}}} \times \left(1 - \frac{1}{2} \max \left(0, \frac{H(P) - \log k/2}{H_{\max}(P) - \log k/2} \right) \right)$$

P : normalized top- k relevance scores
 $p_{\text{top-1}}, p_{\text{GT}} \in P$: top-ranked / labeled-GA scores
 $H(P)$: entropy of P
 $H_{\max}(P) = \log k$: max entropy

GT/Top-1 比 [0, 1]

モデルの自信 [0.5, 1.0]


Inter-GA Recommendation

タスク定義

- 入力: 論文
- 出力: 入力論文の GA を新規作成する際に参考となる既存論文の GA
 - 著者にインスピレーションを与え, より魅力的な図の作成を促す

制約

- 実際に著者が作成した GA や Teaser はマスクする




実験

ベンチマーク手法

- SciGA-145k の CS 分野の論文を対象に各タスクを実施
- 入力クエリは Abstract のみ
- 検索対象の図は画像およびキャプションを使用

▼ (i) Abstract2Caption


[[Yamamoto+, Front. Res. Metr. Anal. '21](#); [Yang+, ICDAR'19](#)]




▼ (ii) GA binary Classification



▼ (iii) Abstract2Figure



▼ (iv) Abstract2Figure w/ caption



実験

Intra-GA Recommendation の評価プロトコル

- 順位依存の評価指標: Recall@k ($R@k$), MRR [[Voorhees+, LREC'00](#)], nDCG@k [[Borges+, ICML'05](#)]
- 平均 $CAR@k$, $CAR@k > 0.5$ となる instance の割合

Inter-GA Recommendation の評価プロトコル


- 参考になる GA とは何か曖昧で GT が一意に定まらない
 - 査読付き論文出版経験のある ML 研究者 15 人を対象に 2AFC User Study を実施
- 人間の好みと整合する軸を Silver-Standard レリバンスラベルとして nDCG@k を評価
 - 分野一致率 : 入力論文と推薦論文の研究分野一致率
 - 意味的一貫性: 入力論文と推薦論文の Abst. 間 S-BERT 類似度 [[Reimers+, EMNLP-IJCNLP'19](#)]
 - 視覚的一貫性: 入力論文と推薦論文の GA 間 CLIPScore [[Hessel+, EMNLP'21](#)]
 - 審美性 : LAION Aesthetic Predictor V2 [[Schuhmann+, NeurIPS'22](#)]

結果 | Intra-GA Recommendation

定量結果

Method	Backbone († Max Token Length)	R@1	R@2	R@3	MRR	nDCG@5	CAR@5	
							Mean	0.5 ↑
(i) Abs2Cap	ROUGE-L [8]	0.394	0.625	0.759	0.601	0.664	0.429	0.448
	METEOR [2]	0.353	0.589	0.737	0.571	0.638	0.404	0.401
	CIDEr [53]	0.277	0.489	0.653	0.500	0.571	0.374	0.089
	BM25 [41]	0.508	0.739	0.849	0.690	0.747	0.528	0.633
	BERTScore [62] († 512)	0.485	0.707	0.819	0.668	0.726	0.505	0.545
(ii) GA-binCl	EfficientNetV2 [47]	0.449	0.674	0.797	0.643	0.703	0.486	0.545
	VIT [9]	0.346	0.606	0.762	0.574	0.647	0.420	0.430
	CLIP image encoder [39]	0.493	0.708	0.826	0.675	0.734	0.518	0.602
	SwinTransformerV2 [29]	0.494	0.712	0.823	0.675	0.730	0.516	0.584
	ConvNeXtV2 [55]	0.483	0.703	0.816	0.667	0.725	0.511	0.577
(iii) Abs2Fig	CLIP [39] († 77)	0.573	0.791	0.877	0.735	0.786	0.573	0.647
	BLIP-2 [26] († 512)	0.578	0.787	0.867	0.737	0.787	0.577	0.649
	X ² -VLM [60] († 40)	0.489	0.711	0.825	0.672	0.730	0.514	0.571
	OpenCLIP [7] († 77)	0.566	0.780	0.870	0.730	0.781	0.567	0.641
	SigLIP2 [50] († 64)	0.558	0.772	0.869	0.724	0.776	0.588	0.636
(iv) Abs2Fig w/cap	Long-CLIP [61] († 248)	0.575	0.783	0.877	0.735	0.785	0.573	0.646
	CLIP [39] († 77)	0.628	0.822	0.902	0.771	0.816	0.610	0.689
	BLIP-2 [26] († 512)	0.557	0.767	0.863	0.721	0.773	0.557	0.626
	X ² -VLM [60] († 40)	0.538	0.757	0.857	0.709	0.763	0.546	0.618
	OpenCLIP [7] († 77)	0.621	0.817	0.905	0.767	0.813	0.603	0.681
	SigLIP2 [50] († 64)	0.527	0.748	0.853	0.702	0.758	0.564	0.593
	Long-CLIP [61] († 248)	0.637	0.826	0.914	0.778	0.824	0.615	0.691

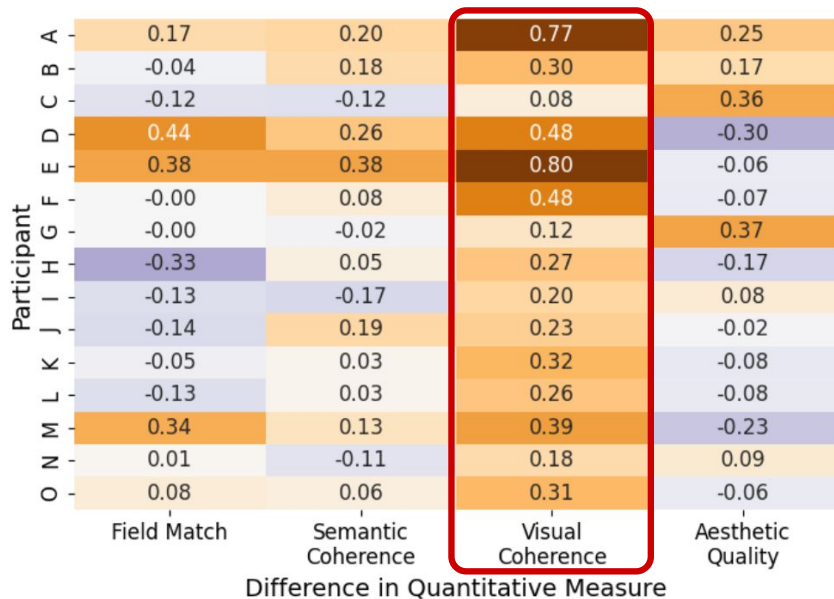
定性結果




- 😊 Abstract, GA, caption の三者のアライメントが効果的
- 😊 概要図, アーキテクチャ図, 結果比較図が上位に, チャート図は下位に
- 😭 GT が背景知識を補足する図の場合, 意図を捉えきれずに大きな推薦ミス
→ このようなケースでは CAR が大きく低下

結果 | Inter-GA Recommendation


ユーザの好みと各軸の点双直列相関係数



ユーザが好んだ手法



ユーザ本人に何を好むか自由記述させた結果



- 視覚的一貫性が最も人間の好みと整合
- ユーザは視覚的な明瞭さやレイアウト, スタイルを重視

結果 | Inter-GA Recommendation

視覚的一貫性をレリバンスとする定量評価

Method	Backbone	nDCG@5	nDCG@10	nDCG@30
(BL) Random Sampling	–	0.770	0.794	0.862
(i) Abs2Cap	ROUGE-L [8]	0.808	0.830	0.887
	METEOR [2]	0.812	0.831	0.889
	CIDEr [53]	0.820	0.839	0.892
	BM25 [41]	0.817	0.836	0.889
	BERTScore [62]	0.807	0.828	0.887
(iii) Abs2Fig	CLIP [39]	0.855	0.870	0.913
	BLIP-2 [26]	0.831	0.849	0.899
	X ² -VLM [60]	0.634	0.640	0.780
	OpenCLIP [7]	0.841	0.858	0.906
	SigLIP 2 [50]	0.811	0.831	0.888
	Long-CLIP [61]	0.853	0.868	0.911
(iv) Abs2Fig w/cap	CLIP [39]	0.822	0.840	0.893
	BLIP-2 [26]	0.815	0.835	0.890
	X ² -VLM [60]	0.786	0.808	0.871
	OpenCLIP [7]	0.824	0.843	0.894
	SigLIP 2 [50]	0.647	0.682	0.801
	Long-CLIP [61]	0.819	0.838	0.891

定性評価


Visual Coherence = 0.846

Visual Coherence = 0.815


Query Abstract


We propose a novel proactive composition framework of wireless energy services in a crowdsourced IoT environment. We define a new model for energy services and requests that includes providers' and consumers' mobility patterns and energy usage behavior. (...)

Author-created GA



Recommended GA





実際に著者が描いた図は入力されていない

😊 入力論文と似たテーマの研究の GA の推薦に成功

1

SciGA | 科学図研究の基盤構築

2


Paper2Figure | 科学図を生成する

既存手法の限界

ラスタ画像生成

- 画素の集合として画像を表現
- PaperBanana [[Zhu+, arXiv'26](#)], NanoBanana [[Google, '25](#)], GPT-Image [[OpenAI, '25](#)]


- 😊 高い審美性
- 😭 文字の視覚的崩壊, 配置や矢印の科学的忠実性欠如, 編集困難



ベクタ画像生成

- SVG, Mermaid などのコードで画像を表現
- StarVector [[Rodriguez+, CVPR'25](#)], AutoFigure-Edit [[Lin+, ACL'26 System Demonstrations](#)]

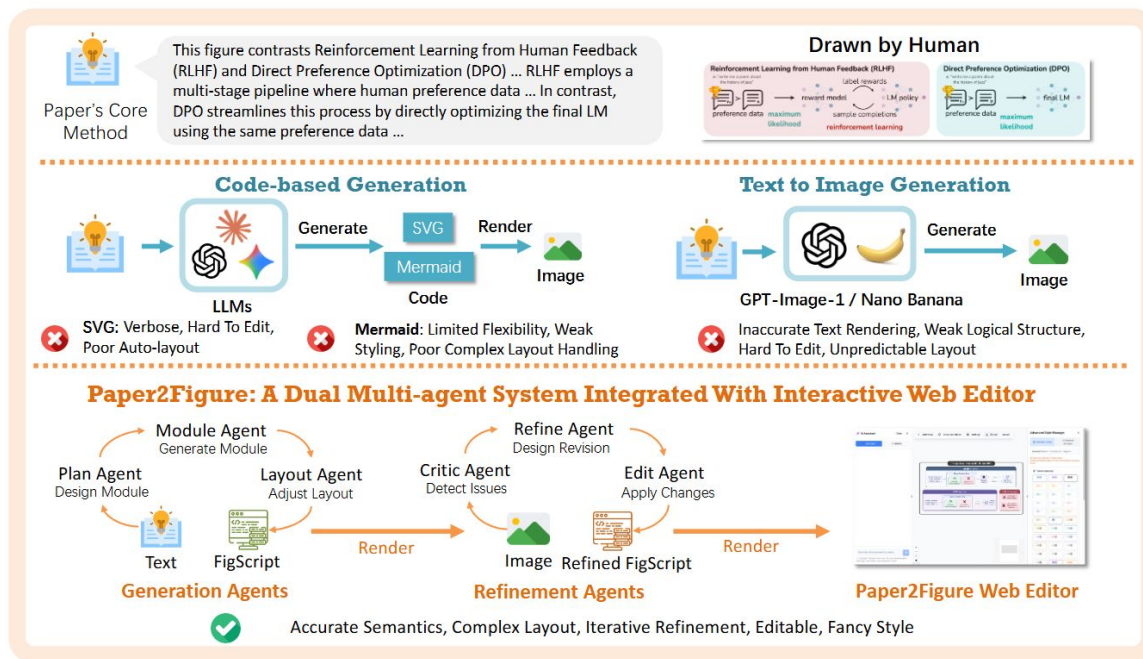
- 😊 正確な矢印の連結, 正確な文字ラベル
- 😭 SVG は自由度が高く, 高い審美性のためには複雑なコードを記述する必要がある
- 😭 Mermaid は簡素な図しか表現できない



→ 科学図生成において, 科学的忠実性と審美性の両立は困難

Paper2Figure

- 新たなベクタ画像形式 FigScript を用いた科学図生成エージェント Paper2Figure を提案
- 科学図生成ベンチマーク Paper2Figure Bench の導入



Paper2Figure

- 新たなベクタ画像形式 FigScript を用いた科学図生成エージェント Paper2Figure を提案
- 科学図生成ベンチマーク Paper2Figure Bench の導入

Generation Agents

FigScript という独自の簡易的なベクタコードを生成


Refinement Agents

レンダリング画像を見て自己修正ループ

Web Editor

独自の Editor 上で自然言語および手動操作による修正が可能

Paper2Figure: A Dual Multi-agent System Integrated With Interactive Web Editor



Accurate Semantics, Complex Layout, Iterative Refinement, Editable, Fancy Style

Paper2Figure | Generation Agents

FigScript

- SVG と Mermaid の中間の複雑さ
- 各図をノード, エッジ, コンテナの階層的なグラフで表現
- 各要素は色, フォント, 枠線の太さ, 矢印の形状, パディング, アイコンの属性を持つ

Plan Agent


- エンティティ, プロセス, 論理的関係を抽出
- モジュール構造, 図の流れ, 階層的構成の計画を画策

Module Agent

- 各モジュールのノード, エッジ, コンテナを構築
- 各ノードのテキストラベルを構築

Layout Agent

- 各エッジの間隔を調整, グループ化し, FigScript を記述



Paper2Figure | Refinement Agents

Critic Agent


- モジュールの配置ミス, テキストの整列の不統一, 色の不均衡, 可読性の問題を検出

Refine Agent

- FigScript の修正計画を画策


Edit Agent

- 修正された FigScript を記述



Paper2Figure | Web Editor

- 自然言語を入力とするチャットパネル
- 手動でモジュールの移動やテキストの修正が可能なライブキャンバス




Paper2Figure Bench

データセット

- 2023年以降の論文 100 本
- 各論文の図 100 枚と生成・人手検証されたキャプション 100件


評価プロトコル

- 以下の3項目のルーブリックを構築
 1. Accuracy: モジュールの網羅性, 関係と方向の一貫性, 用語と記号の整合性
 2. Beauty: 配置とグループ化, 余白, 線のスタイルと終点, 文字と色の可読性, 枠線
 3. Completeness: 生成画像から生成されたキャプションと元のキャプション間の一貫性
- LLM-as-a-Judge で 0, 50, 100 の3段階でスコアを与え, 平均値を算出



結果

定量結果



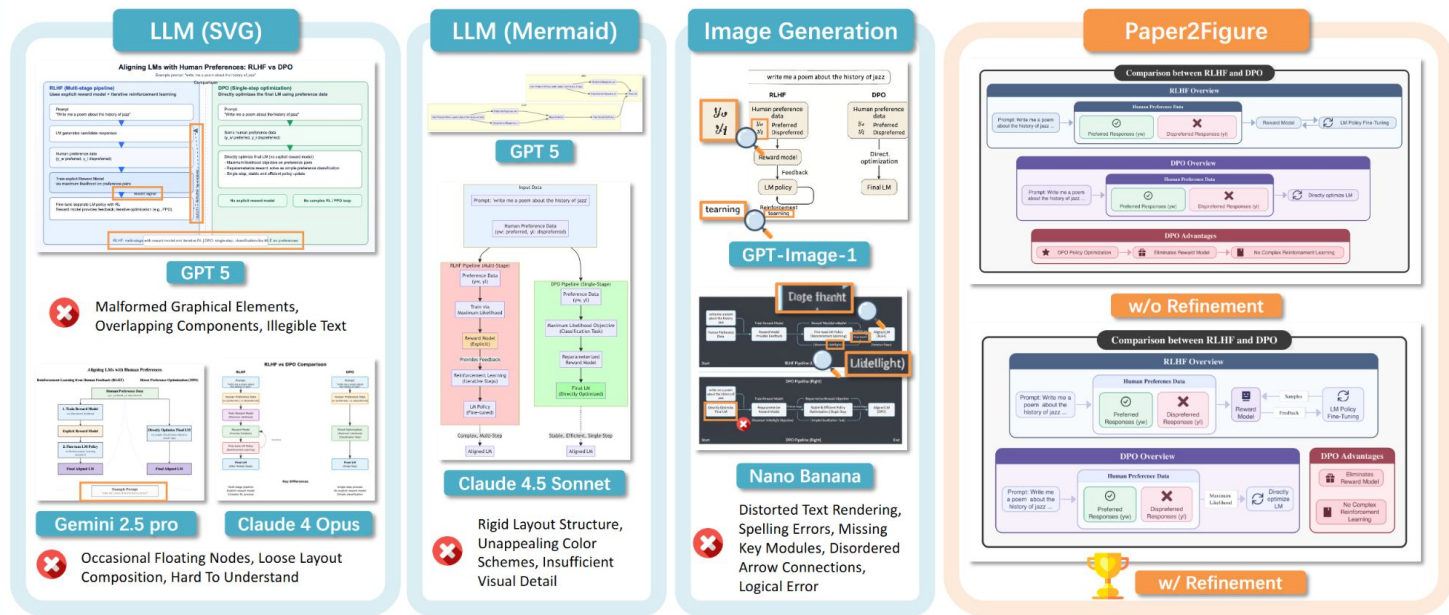
▼ Paper2Figure Bench の自動評価とUserStudyとの相関

Methods	Cosine↑	Pearson ↑	Spearman ↑
Paper2Figure Bench	0.8652	0.7345	0.7289

😊 全指標において, フロンティアモデルでの SVG 生成, 画像生成より優れた結果に

結果

定性結果



😄 レイアウトの破綻や文字の崩れなく、科学的忠実性・審美性の高い科学図生成を実現
 😭 デザインの多様性, 編集可能な操作も限定的

まとめ

SciGA

- 論文のポンチ絵を「理解・検索・評価」する研究基盤を構築

Paper2Figure

- 科学的忠実性・審美性の高い科学図の生成・評価・編集を支援
- 気になったところ
 - 入力が論文ではなくキャプションであり, ユーザが何を描くかを事前に考える必要あり
 - FigScript で操作できる属性やレイアウトが限定で, デザイン均質化の懸念

残る課題と今後の展望

- 研究成果物に基づく, 何を描くかの適切な選択・構造化
- 科学的忠実性・審美性に加え, デザインの多様性と編集操作の自由度を両立した生成