

OMD-5 ほうじ茶



チーム紹介

川田 拓朗(M2)
ルールベース処理実装
倉本 真菜(M2)
スライド作成等
田窪 真大(B4)
top-k処理実装
山下 伊織(B4)
データ拡張
大塚 雄貴(B4)
マージ処理
大田 眞滉(B3)
ルールベース処理実装

チーム名の由来
メンバー中、2名がほうじ茶を持っていたから
(しかも、違う種類)




アプローチ

とにかくルールベースで弾けるだけ弾く

ルールベース

- 著者が正確か
- Survey 論文として引用しているが, Survey 論文でない
- 論文出版年が正確か



推論

モデル: ModernBERT Japanese 70M([sbintuitions/modernbert-ja-70m](https://huggingface.co/sbintuitions/modernbert-ja-70m))

- 引用文脈と論文のタイトル・概要・本文からTF-IDFで関連度の高い文を抽出(top-k)
→BERT系モデルに入力して引用の妥当性を検証

間に合わなかった……


日本語論文と英語論文で分けて処理

データ拡張

citation_contextがシャッフルされたデータが結構あった

→シャッフルを紐解いて元の正しい論文と対応させたデータを追加
(ラベリング、論文のマッチングはエージェントに委託)

id	1		id	2
citation_context	hogehogeの内容		citation_context	piyopiyoの内容
cited_paper_id	piyopiyoの論文		cited_paper_id	hogehogeの論文
label	0		label	0



入れ替えれば正例のデータとして拡張ができる！！

困ったこと

Colabが落ちる危機に 怯え続ける

- 処理を個々で実装してマージしているため、マージ担当が常にColabと格闘

得られたこと

とにかく喋ってみる

- 負例のパターンをとにかく分析してみる
- 問題を切り分けて考える

使用ツール・設定

- GPT-5.6 / Claude-Opus 5

使用目的:コーディング・データ拡張

- 実験設定

項目	設定
CV分割数	5
最大系列長	512
学習バッチサイズ	8
最大 Epoch	5
学習率	3×10^{-5}