

[S2-P30] Activation Steering における文章崩壊の抑制に向けた初期検討

西山 天, 川田 拓朗, 北田 俊輔, 永井 大地, 彌富 仁 法政大学大学院 理工学研究科
{sora.nishiyama.2w@stu.,iyatomi@}hosei.ac.jp




本研究の
ポイント

- 🙄 LLM におけるステアリングは内部状態に強制的に介入するため, 生成が不安定
- 😊 介入強度の適応的調整と選択的介入で既存手法の課題解決を目指す手法の提案

Background

Activation Steering (AS) [Subramani+, ACL'22; Rimsky+ ACL'24; Liu+ ICML'24]

- 😊 LLM の潜在表現を直接操作することで生成を制御
- ⚙️ 従来手法では, Love / Hate のような Pos. / Neg. の対照サンプルから各層のステアリングベクトルを算出し, 各トークン出力で共通に適用
- 🙄 意図せず他の概念にも影響を及ぼしてしまう
- 🙄 介入強度に敏感で不要な部分にまで介入してしまう
- ➡ 無用な反復が多い文章, 意味の破綻した文章の生成を誘発



CASTLE | 一様な潜在表現への介入を避け, 2つの機構で潜在表現の変換と介入箇所・強度を適応的に制御

Calibrated Intervener (CI) - どう介入するか -

- 目的概念への変換に必要な介入のみを行う
- 元の潜在空間を極力保持し, 不要な変化を抑制

初期検討として MidSteer [Gaintseva+, ICML'26] で実装

- アフィン変換でステアリングされた潜在表現 $h' \in \mathbb{R}^d$ を得る
$$h' = Ah + b \quad h: \text{対象層の元の潜在表現}$$
- 潜在表現 h と概念 c の共起関係を以下の共分散行列で表す
$$\Sigma_{h,z_c} \in \mathbb{R}^{d \times 1} \quad z_c: \text{入力文が概念 } c \text{ であるか否かを示すバイナリベクトル}$$
- 最小限の介入で概念 $c_1 \rightarrow c_2$ の変換を達成する A, b を求める
$$(A^*, b^*) = \underset{A, b}{\operatorname{argmin}} \|h' - h\|^2 = \underset{A, b}{\operatorname{argmin}} \|(Ah + b) - h\|^2$$

s.t. $\Sigma_{h', z_{c_1}} = \Sigma_{h, z_{c_2}}$

↳ この制約により, 概念 c_1 入力時, 概念 c_2 入力時と同じ表現特性となるように

Selective Intervener (SI) - どこに・どれだけ介入するか -

- 生成時の各トークン位置で介入強度を調整
- 必要な箇所にのみ選択的に介入し, 過剰介入を抑制

初期検討として PSR [Heyman+, ICML'26] で実装

- i 番目のトークン出力における, h' を以下の変換で得る
$$h' = h + \lambda_i v, \quad \text{where } \lambda_i = \operatorname{ReLU}(h^\top w_i + b_i)$$
 - 実際の対象サンプルを用いた Prompting による潜在表現の変化 Δ_{PS} を模倣するステアリングベクトルを求める
$$(w_i^*, b_i^*, v^*) = \underset{w_i, b_i, v}{\operatorname{argmin}} \|\lambda_i v - \Delta_{\text{PS}}\|^2 = \underset{w_i, b_i, v}{\operatorname{argmin}} \|\operatorname{ReLU}(h^\top w_i + b_i) v - \Delta_{\text{PS}}\|^2$$
-

Experimental Setup

- MidSteer [Gaintseva+, ICML'26] に従い, horses → motorcycles の概念変換実験を実施 (各文 10 サンプルずつ生成)
- データセット
 - 学習用: Alpaca (50,000 件) [tatsu-lab/alpaca]
 - 対照サンプル (1,000 件) [Gaintseva+, ICML'26]
 - 評価用: horses に関する質問文 (81 件) [Gaintseva+, ICML'26]

バックボーンモデル

- Llama-3-8B-Instruct [Grattafiori+, 24]

評価指標

- $S_{\text{horses}}, S_{\text{motorcycles}}$: Llama-3.1-8B-Instruct [Grattafiori+, 24] を用いた LLM-as-a-Judge による各概念の達成度 (0-10点)
- distinct-3: 3-gram ユニーク率の平均

Results & Discussion

	$S_{\text{horses}} \downarrow$	$S_{\text{motorcycles}} \uparrow$	distinct-3 $\uparrow$
Baseline (ステアリング無し)	8.7679	0.4506	0.9985
CAA [Rimsky+, ACL'24]	3.8383	3.0728	0.9994
MidSteer [Gaintseva+, ICML'26]	1.2840	8.5284	0.9990
PSR [Heyman+, ICML'26]	1.1420	8.6222	0.9987
CASTLE (Ours) w / CI → SI	0.8728	8.7395	0.9990
w/ SI → CI	0.0358	0.5420	0.9709

- 提案手法の高耐性の要因:
学習された「動的位置選択ゲート」による文脈に応じた選択的介入が崩壊回避の主因と推測
- 提案モジュールの適用順: CI → SI vs. SI → CI
CI が無介入時の活性化構造を前提とするため, 先に SI を適用すると活性化分布が変化し, CI の補正が想定した条件から外れてしまう

失敗例 (CAA [Rimsky+ ACL'24])

Prompt : Write a short story about a horses

Output : ... Let's ride to our trip on January 1st 2000 of your best friend for an in-personal assistant. <|eot_id|><|eot_id|><|eot_id|> ...

成功例 (ours)

Prompt : Write a short story about a horses

Output : The sun was setting over the desert landscape as Jack revved up his motorcycle, a sleek and powerful beast of a bike. He had been ...

Future Work

- CI / SI に特化した介入機構・学習法の設計
- 概念変換から概念除去・抑制への拡張

